CodificaMed: codificación automática CIE-10 de notas clínicas mediante procesamiento de lenguaje natural
Informe ejecutivo

Micaela Quispillo

Código estudiantil: 7553

Escuela Superior Politécnica de Chimborazo

Facultad de Informática y Electrónica

Carrera de Ingeniería en Software

Asignatura: Base de Conocimiento

Docente: Ing. Isaac Torres

4 de noviembre de 2026

Resumen ejecutivo

CodificaMed es un prototipo académico que propone códigos CIE-10 para notas clínicas ficticias en español y muestra la evidencia textual de cada sugerencia. Incluye análisis del contexto de negación, recuperación de candidatos, validación y una interfaz para seleccionar entre un modelo local y una API externa. Se empleó un catálogo de 98 288 códigos y diez notas ficticias con 30 etiquetas. Se aprobaron 83 pruebas automatizadas. En la comparación base, ambos modelos obtuvieron un F1 micro de 33,33 %. La recuperación con TF-IDF aumentó la cobertura de códigos confirmados del 37,50 % al 75,00 %. Estas cifras son exploratorias; las etiquetas todavía requieren revisión clínica independiente.

Problemática y objetivo

La codificación manual exige interpretar notas escritas en texto libre, que pueden incluir abreviaturas, síntomas, diagnósticos y expresiones como «niega fiebre» o «se descarta neumonía». Una lectura incorrecta puede generar códigos equivocados y afectar los registros y procesos administrativos de salud, como plantea el enunciado de la actividad (Torres, s. f.).

El objetivo fue desarrollar una aplicación que reciba notas ficticias, sugiera códigos CIE-10 y presente la frase que respalda cada propuesta. El sistema debe distinguir los diagnósticos confirmados de los negados y descartados y permitir la comparación entre un modelo local y una API externa. Se trata de una herramienta académica de apoyo a la revisión, no de un sistema de diagnóstico clínico.

Aplicación de las seis fases de CRISP-ML(Q)

El desarrollo se organizó mediante CRISP-ML(Q), modelo que incorpora actividades de calidad en las diferentes etapas de un proyecto de aprendizaje automático (Studer et al., 2021).

Fase 1. Comprensión del problema y los datos

Se definió el problema de interpretar diagnósticos en español sin confundir afirmaciones con negaciones o sospechas. Se establecieron como salidas el código, su descripción, el estado clínico y la evidencia literal. Se decidió trabajar únicamente con notas inventadas. El catálogo

local, asociado a CodiEsp y a CIE-10-CM de 2018, contiene 98 288 códigos; este recurso sirve para consultar descripciones y comprobar la existencia de códigos.

Fase 2. Preparación e ingeniería de datos

Se organizó un conjunto de diez notas ficticias en JSON. Las etiquetas incluyen código, descripción, estado y evidencia. La versión auditada reúne 30 etiquetas: 16 confirmadas, ocho negadas, cuatro descartadas y dos sospechadas. El preprocesamiento divide las notas en fragmentos y prepara el texto para detectar expresiones clínicas. Se construyó un vocabulario manual de 28 entradas y sinónimos, entre ellos «HTA». La auditoría final no detectó problemas estructurales; esto no certifica la pertinencia médica de todos los códigos.

Fase 3. Ingeniería de modelos

Se implementó detección léxica de entidades clínicas y análisis de contexto para reconocer negaciones, descartes y sospechas. Los candidatos se obtienen del vocabulario y, opcionalmente, mediante embeddings multilingües o TF-IDF sobre las descripciones del catálogo. Se envían hasta 15 candidatos a Ollama (*Llama 3.2 3B*) o a Gemini (*3.5 Flash Lite*), según la configuración. Los modelos no fueron reentrenados. La respuesta se valida por existencia del código, pertenencia a los candidatos, estado y evidencia literal.

Fase 4. Evaluación y aseguramiento de calidad

Se ejecutaron 83 pruebas automatizadas sin fallos y se revisó la estructura del conjunto de evaluación. Para las métricas se compararon los códigos confirmados por coincidencia exacta y se contabilizaron verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN). Se calcularon precisión, recall y F1 micro. Los estados negado, descartado y sospechado no se contabilizaron como positivos; su clasificación no se evaluó por separado. Las pruebas se realizaron sobre las mismas diez notas ficticias para ambos modelos.

Fase 5. Despliegue del prototipo

Se creó una interfaz local con Streamlit para escribir una nota, elegir el proveedor, activar o desactivar embeddings y consultar diagnósticos con evidencias. La aplicación se verificó en *localhost:8501*. En una demostración con Gemini, la nota «Se confirma hipertensión arterial

esencial. Niega fiebre. Se descarta neumonía» produjo *I10* confirmado, *R50.9* negado y *J18.9* descartado. Se registraron 15 candidatos y 8,33 segundos de ejecución. Se conserva un archivo de configuración de ejemplo sin claves reales.

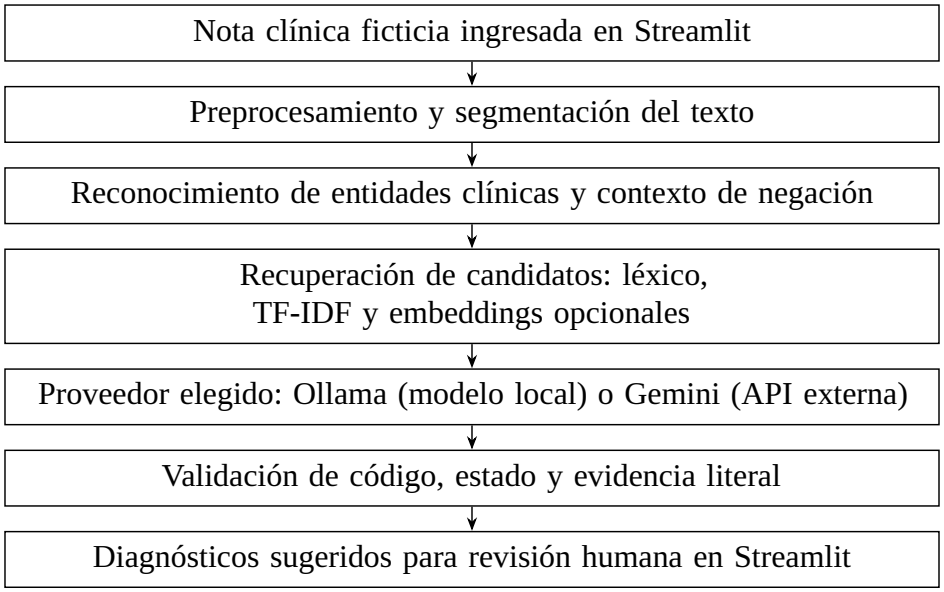
Fase 6. Monitoreo y mantenimiento

Se guardaron resultados de ejecución en CSV y JSON, junto con las salidas de pruebas y los rechazos de validación. Como trabajo posterior se propone revisar las versiones del catálogo, los errores de API, la latencia y las sugerencias incorrectas utilizando notas nuevas con anotación independiente. No se implementó monitoreo clínico de producción: CodificaMed continúa siendo un prototipo académico.

Arquitectura de la solución

La arquitectura separa la entrada, el procesamiento del texto, la recuperación de códigos, la inferencia y la validación. El mismo validador se utiliza para ambos proveedores y exige evidencias tomadas de la nota original.

Figura 1
Arquitectura del procesamiento de CodificaMed



Nota. Elaboración propia a partir de los módulos implementados en el proyecto. Las dos opciones de proveedor comparten el mismo flujo de validación.

Los módulos *src/nlp*, *src/retrieval* y *src/providers* gestionan, respectivamente, el análisis textual, la recuperación y los modelos. *src/evaluation* calcula las métricas; *app.py* contiene la interfaz; y *scripts* reúne la auditoría y la evaluación.

Resultados de evaluación y comparación

La evaluación base se realizó en diez notas con embeddings y TF-IDF desactivados. Los 16 códigos confirmados de referencia se compararon por código exacto. El F1 micro resume los aciertos y errores acumulados de todas las notas, no el promedio de los F1 individuales.

Tabla 1
Comparación entre Gemini y Ollama en diez notas sin TF-IDF

Indicador	Gemini (API)	Ollama (local)
Notas procesadas	10	10
Verdaderos positivos (VP)	5	4
Falsos positivos (FP)	9	4
Falsos negativos (FN)	11	12
Precisión micro	35,71 %	50,00 %
Recall micro	31,25 %	25,00 %
F1 micro	33,33 %	33,33 %

Nota. Resultados reales del evaluador; únicamente cuentan como positivos los códigos confirmados.

Gemini recuperó cinco diagnósticos correctos, pero produjo nueve falsos positivos. Ollama presentó mayor precisión, con menos falsos positivos, y un recall más bajo. Ambos obtuvieron F1 micro de 33,33 %. Los errores incluyeron códigos generales en lugar de específicos y omisiones de diagnósticos. No puede concluirse que un proveedor sea superior con un conjunto tan pequeño.

Tabla 2
Cobertura de candidatos confirmados y piloto con TF-IDF

Medición	Sin TF-IDF	Con TF-IDF
Cobertura en diez notas	6/16 (37,50 %)	12/16 (75,00 %)

Nota. La cobertura indica cuántos códigos correctos estaban disponibles entre los candidatos; no equivale al F1 del modelo.

En el piloto de dos notas con TF-IDF, sin embeddings, Gemini obtuvo precisión de 50,00 %, recall de 100,00 % y F1 de 66,67 %. Ollama no produjo confirmaciones (precisión indefinida y F1 de 0,00 %). Estos resultados no sustituyen la evaluación de diez notas y son provisionales, pues las etiquetas requieren validación clínica independiente.

Conclusiones

El prototipo CodificaMed procesa notas clínicas ficticias en español y presenta sugerencias CIE-10 acompañadas de evidencia literal. La aplicación permitió seleccionar entre Gemini, mediante una API externa, y Llama 3.2 3B, mediante Ollama en el equipo local. En la demostración de la interfaz se identificó una hipertensión confirmada, una fiebre negada y una neumonía descartada.

En la evaluación de diez notas, ambos proveedores obtuvieron un F1 micro de 33,33 %. Ollama alcanzó mayor precisión (50,00 %) y Gemini mayor recall (31,25 %). La búsqueda TF-IDF elevó la cobertura de candidatos confirmados de 6 de 16 a 12 de 16, pero todavía no se ha comprobado su efecto en el F1 sobre las diez notas. Las 83 pruebas automatizadas se ejecutaron correctamente.

Limitaciones

Se utilizaron diez notas ficticias y 30 etiquetas, sin validación clínica independiente. Aunque la auditoría no encontró errores estructurales, los resultados no permiten estimar el desempeño con pacientes reales ni comparar definitivamente ambos modelos.

Las métricas consideran solo códigos confirmados por coincidencia exacta; no evalúan por separado negaciones, descartes ni sospechas. El índice de embeddings es limitado y Ollama presentó una incidencia con esa opción, por lo que la comparación se realizó sin embeddings. El prototipo no dispone de monitoreo clínico en producción. Una evaluación posterior requiere nuevas notas ficticias, anotación independiente y pruebas de estabilidad, latencia y actualización del catálogo.

Referencias

Miranda-Escalada, A., & Krallinger, M. (2020). *CodiEsp codes: List of valid CIE10 codes for the CodiEsp task* [Conjunto de datos]. Zenodo. https://doi.org/10.5281/zenodo.3706838

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction, 3*(2), 392–413. https://doi.org/10.3390/make3020020

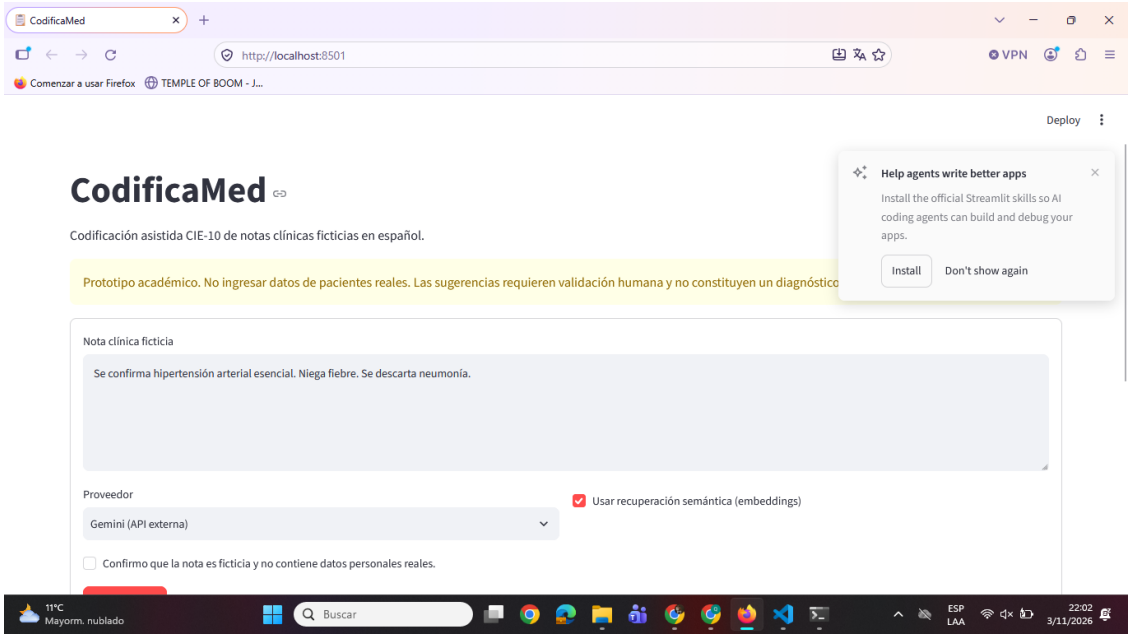
Torres, I. (s. f.). *Tarea: CodificaMed. Codificación automática CIE-10 de historias clínicas con PLN* [Enunciado de actividad]. Escuela Superior Politécnica de Chimborazo.

Apéndice A. Evidencias de la aplicación CodificaMed

Las siguientes capturas corresponden a las pantallas originales del prototipo y del entorno de desarrollo. Se presentan completas, sin recortes ni modificaciones de su contenido. Las imágenes se conservaron en su proporción original.

Figura A1

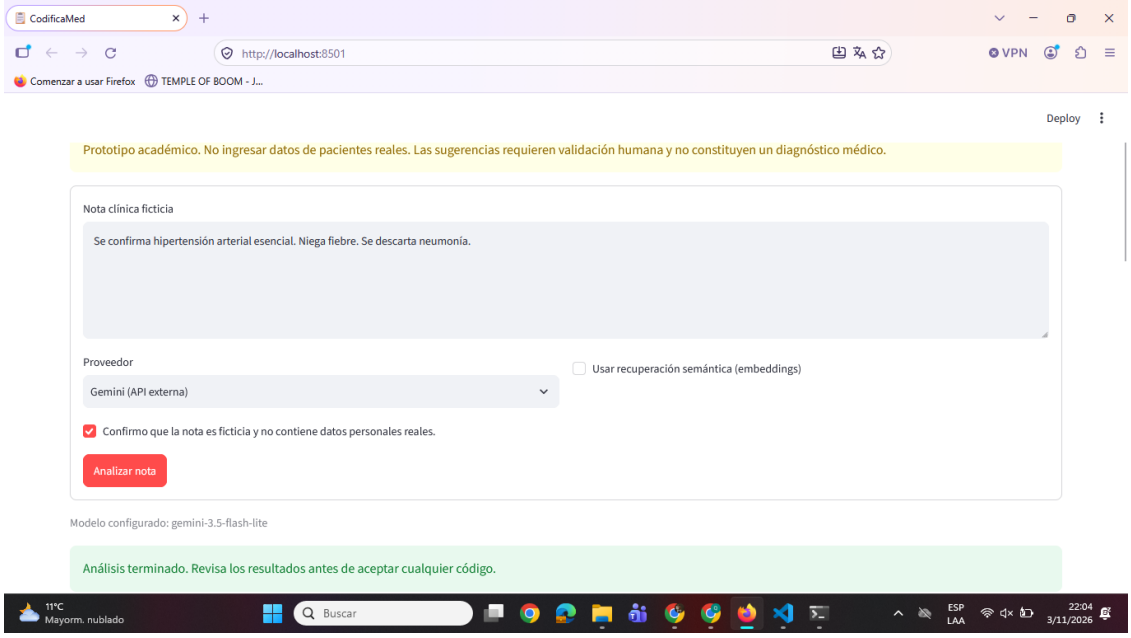
Pantalla de inicio del prototipo en Streamlit



Nota. Interfaz local disponible mediante el navegador web.

Figura A2

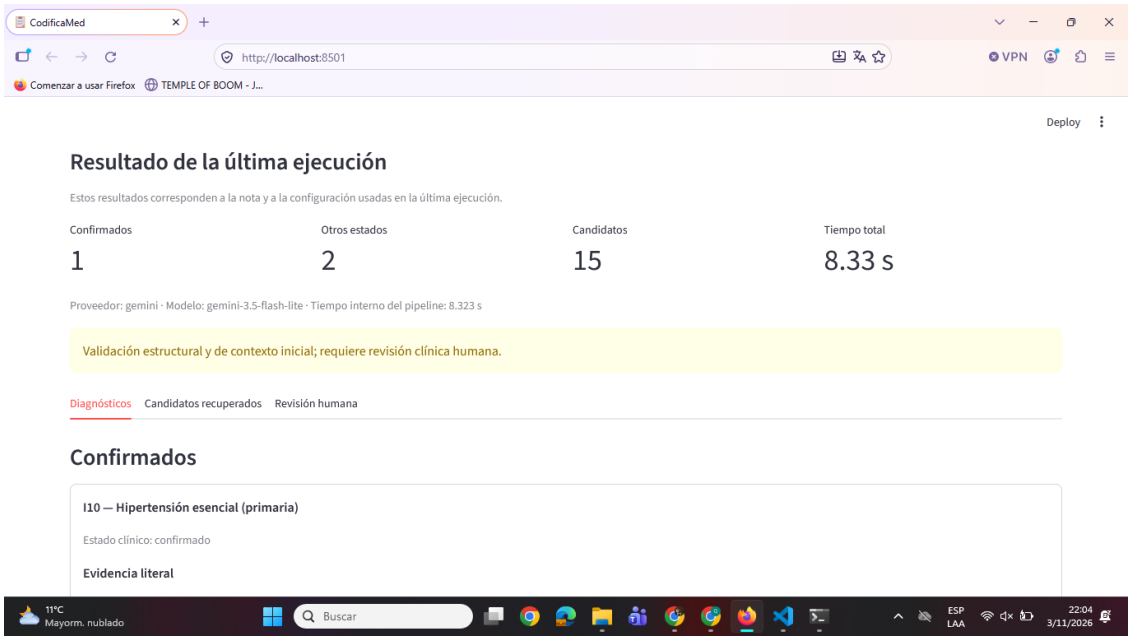
Ingreso de nota clínica y selección de Gemini



Nota. Nota ficticia, consentimiento marcado y recuperación por embeddings desactivada.

Figura A3

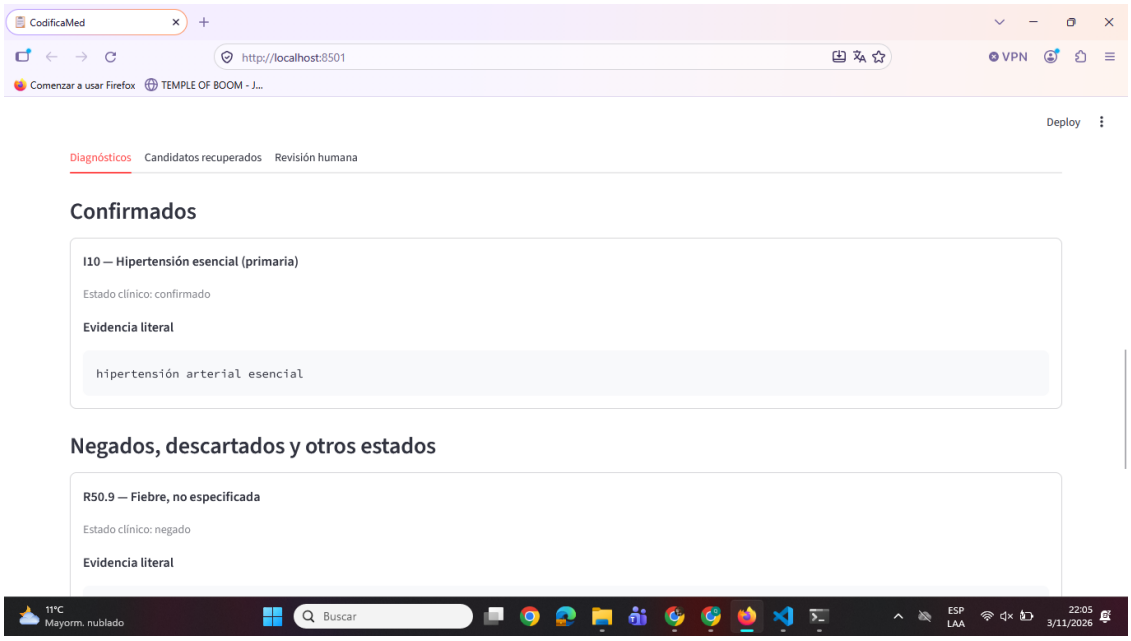
Resumen de la ejecución del modelo



Nota. Se muestran un diagnóstico confirmado, dos de otros estados, 15 candidatos y 8,33 segundos.

Figura A4

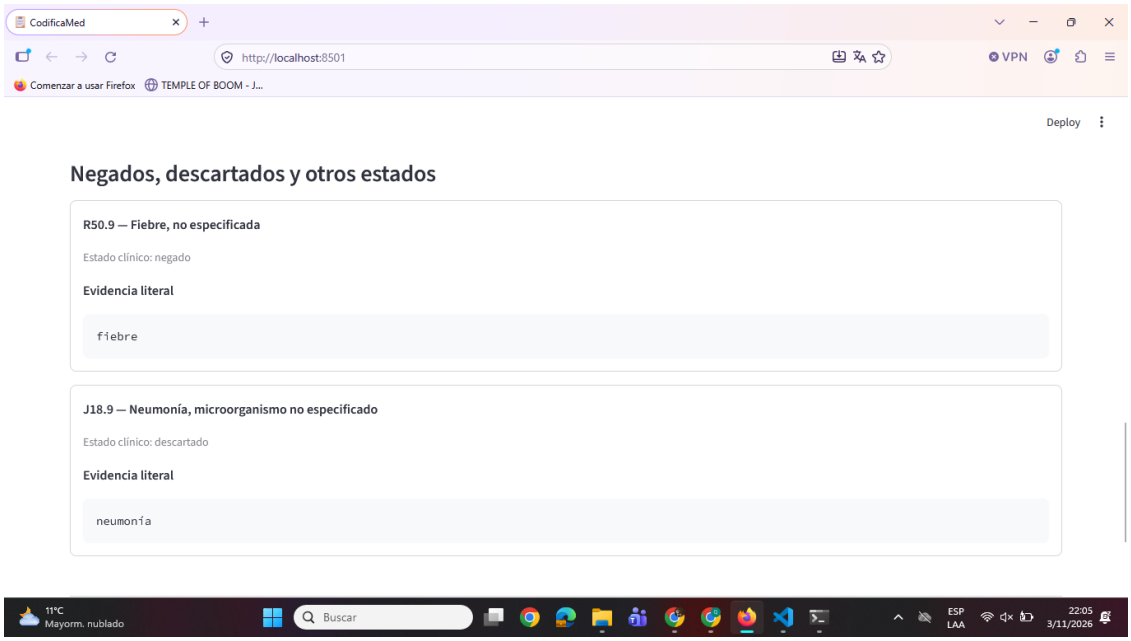
Código confirmado y evidencia literal



Nota. El sistema presenta I10 para hipertensión arterial esencial y la frase que respalda la sugerencia.

Figura A5

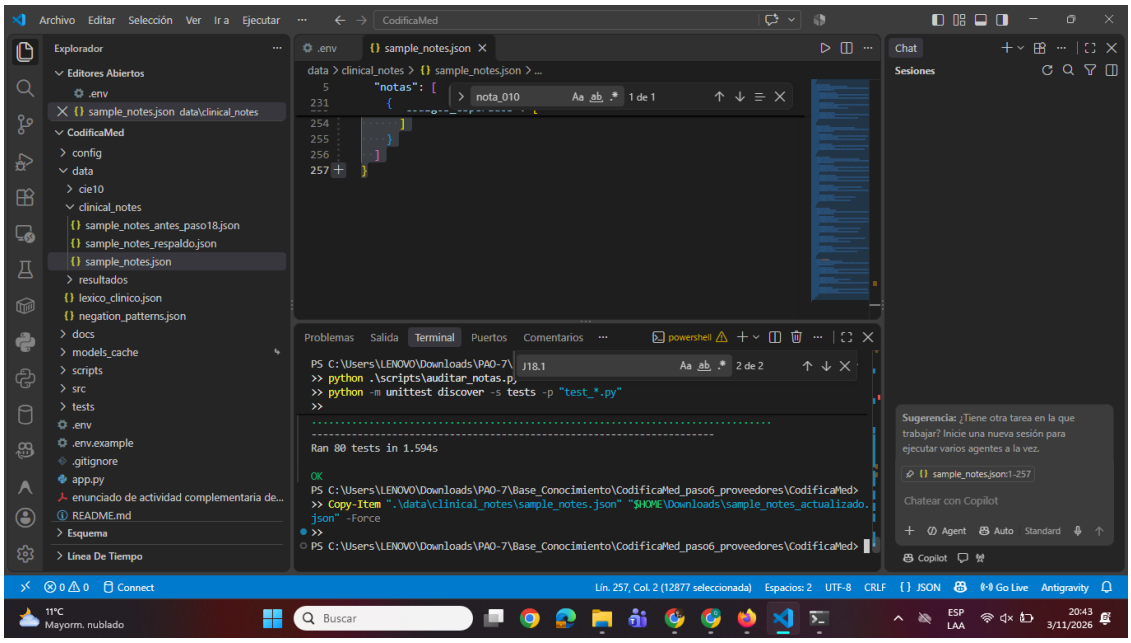
Códigos negados y descartados



Nota. Se observan R50.9 negado y J18.9 descartado, diferenciados de los confirmados.

Figura A6

Estructura del proyecto en Visual Studio Code



Nota. Captura del entorno de desarrollo y la revisión de notas durante la implementación.